

Analisis Saturasi & Halusinasi pada RAG

Anggota Kelompok:

1. Athaya Naura Khalilah (23/512716/PA/21899)
2. Geraldine Angelie Tari Damauly Hutagalung (23/512663/PA/21894)
3. Syafran Abdillah Erdin (23/521752/PA/22444)

1. METODE

1.1 Arsitektur RAG

Sistem dibangun menggunakan pendekatan Retrieval-Augmented Generation (RAG) yang terdiri atas dua komponen utama, yaitu retriever dan generator. Pertanyaan pengguna terlebih dahulu digunakan untuk mencari dokumen yang relevan dari basis pengetahuan. Dokumen hasil retrieval kemudian diberikan sebagai konteks kepada model bahasa untuk menghasilkan jawaban beserta sitasi dokumen yang digunakan.

1.2 Model yang Digunakan

Pada tahap retrieval, dokumen direpresentasikan menggunakan model embedding paraphrase-multilingual-MiniLM-L12-v2 dan disimpan dalam indeks FAISS untuk mendukung pencarian dokumen berdasarkan kemiripan vektor. Eksperimen dilakukan menggunakan variasi nilai Top-K sebesar 1, 3, 5, dan 10 untuk menganalisis pengaruh jumlah dokumen konteks terhadap kualitas jawaban dan sitasi. Pada tahap generasi, digunakan model Qwen2.5-1.5B-Instruct. Model menerima pertanyaan dan dokumen hasil retrieval yang telah diformat sebagai konteks. Setiap dokumen diberi penanda numerik, seperti [1], [2], dan [3], sehingga model dapat merujuk dokumen tersebut melalui sitasi pada jawaban yang dihasilkan.

1.3 Rancangan Prompt

Prompt dirancang agar model hanya menggunakan informasi yang tersedia pada dokumen hasil retrieval. Pertanyaan dan dokumen konteks diberikan dalam format terstruktur, kemudian model diminta untuk menghasilkan jawaban berdasarkan konteks yang tersedia serta menyertakan sitasi dokumen yang digunakan sebagai sumber informasi.

Contoh struktur prompt yang digunakan ditunjukkan sebagai berikut:

None

SYSTEM:

"Anda adalah sistem RAG. Anda hanya boleh menjawab berdasarkan konteks yang diberikan. "

"Setiap jawaban faktual WAJIB memiliki sitasi dalam format [1], [2], dan seterusnya. "

"Jika jawaban tidak memiliki sitasi, jawaban dianggap tidak valid. "

"Jangan menggunakan pengetahuan di luar konteks."

USER:

Gunakan konteks berikut untuk menjawab pertanyaan.

KONTEKS:

{formatted_context}

PERTANYAAN:

{question}

ATURAN JAWABAN:

1. Jawab dalam bahasa Indonesia.
2. Jawab singkat dan langsung.
3. Setiap kalimat jawaban faktual WAJIB diakhiri sitasi, contoh: "Pasuruan, Jawa Timur [1]."
4. Gunakan hanya nomor sitasi yang tersedia pada konteks.
5. Jangan membuat sitasi yang tidak tersedia pada konteks.
6. Jika jawaban tidak ditemukan pada konteks, tulis:
"Jawaban tidak ditemukan pada konteks yang diberikan."

CONTOH FORMAT JAWABAN:

Pasuruan, Jawa Timur [1].

JAWABAN:

2. HASIL EKSPERIMEN

2.1 Hasil Retrieval Dokumen

Tahap retrieval dilakukan menggunakan FAISS dengan representasi dokumen yang diperoleh dari model embedding paraphrase-multilingual-MiniLM-L12-v2. Untuk setiap pertanyaan, sistem mengambil sejumlah dokumen dengan tingkat kemiripan tertinggi sesuai nilai Top-K yang digunakan pada eksperimen.

Peringkat	Dokumen Hasil Retrieval	Relevansi
1	Dr. Ernest François Eugène Douwes Dekker lahir di Pasuruan, Jawa Timur.	Relevan
2	Desiderius Erasmus dilaporkan lahir di Rotterdam.	Tidak relevan
3	Ernest Hemingway dilahirkan di Oak Park, Illinois.	Tidak relevan

Tabel 2.1 Hasil Retrieval untuk Pertanyaan Lokasi Kelahiran Dr. Ernest François Eugène Douwes Dekker

Berdasarkan hasil retrieval, dokumen yang mengandung jawaban benar berhasil ditempatkan pada peringkat pertama. Sementara itu, dokumen pada peringkat kedua dan ketiga tidak berkaitan dengan Dr. Ernest François Eugène Douwes Dekker, tetapi masih memiliki kemiripan konteks karena sama-sama memuat informasi mengenai tokoh dan lokasi kelahiran. Hasil tersebut menunjukkan bahwa retriever mampu mengidentifikasi dokumen yang relevan dan menempatkannya pada posisi teratas. Meskipun demikian, masih ditemukan dokumen lain dengan kemiripan semantik yang ikut terambil pada peringkat berikutnya. Temuan ini menunjukkan bahwa proses retrieval tidak hanya mempertimbangkan kesamaan entitas yang ditanyakan, tetapi juga kesamaan konteks informasi yang terdapat pada dokumen.

2.2. Hasil Generasi Jawaban

Jawaban dihasilkan menggunakan model Qwen2.5-1.5B-Instruct berdasarkan konteks yang diperoleh dari tahap retrieval. Setiap dokumen konteks diberikan penanda numerik seperti [1], [2], dan seterusnya agar model dapat menyertakan sitasi pada jawaban yang dihasilkan. Tabel 2.2 menunjukkan contoh hasil generasi jawaban untuk pertanyaan “Kapan Universitas Delhi berdiri?” pada variasi nilai Top-K = 1, 3, 5, dan 10.

Top-K	Pertanyaan	Ground Truth	Jawaban Model	Sitasi	Citation Hit
1	Kapan Universitas Delhi berdiri?	1922	Universitas Delhi berdiri pada tahun 1922.	-	False
3	Kapan Universitas Delhi berdiri?	1922	Universitas Delhi dibuat pada tahun 1922. [1]	[1]	True
5	Kapan Universitas Delhi berdiri?	1922	1922 [1].	[1]	True
10	Kapan Universitas Delhi berdiri?	1922	1922 [1].	[1]	True

Tabel 2.2 Hasil Generasi Jawaban dan Sitasi pada Berbagai Nilai Top-K

Berdasarkan Tabel 2.2, model mampu menghasilkan jawaban yang sesuai dengan ground truth, yaitu tahun 1922, pada seluruh variasi nilai Top-K. Namun, terdapat perbedaan pada kelengkapan dan ketepatan sitasi. Pada K=1, model menghasilkan jawaban yang benar, tetapi tidak menyertakan sitasi sehingga Citation Hit bernilai False. Pada K=3, K=5, dan K=10, model menghasilkan jawaban dengan sitasi [1] dan Citation Hit bernilai True. Hasil ini menunjukkan bahwa jawaban yang benar secara isi belum tentu memiliki sitasi yang valid, sehingga evaluasi sitasi tetap diperlukan selain evaluasi kualitas jawaban menggunakan ROUGE, BLEU, dan BERTScore.

2.3 Hasil Evaluasi Kualitas Jawaban

Evaluasi kualitas jawaban dilakukan terhadap 50 pertanyaan uji menggunakan empat variasi nilai Top-K, yaitu K = 1, 3, 5, dan 10. Karena setiap pertanyaan diuji pada seluruh nilai K, total dihasilkan 200 jawaban untuk proses evaluasi.


Top-K	ROUGE-1	ROUGE-2	ROUGE-L	BLEU	BERTScore F1
1	0.2901	0.1843	0.2807	16.9753	0.6966
3	0.3416	0.2229	0.3401	17.5177	0.7130
5	0.3390	0.2215	0.3403	17.2756	0.7078
10	0.3349	0.2086	0.3344	23.0064	0.7141

Tabel 2.3 Hasil Evaluasi Kualitas Jawaban

Berdasarkan hasil evaluasi, nilai ROUGE-1 berada pada rentang 0,2901 hingga 0,3416, sedangkan ROUGE-2 berada pada rentang 0,1843 hingga 0,2229. Nilai ROUGE-L berada pada rentang 0,2807 hingga 0,3403.

Untuk metrik BLEU, nilai yang diperoleh berada pada rentang 16,9753 hingga 23,0064, sementara BERTScore F1 berada pada rentang 0,6966 hingga 0,7141.

Secara umum, performa kualitas jawaban meningkat dari K=1 ke K=3, terutama pada metrik ROUGE dan BERTScore. Namun, setelah K bertambah menjadi 5 dan 10, peningkatan tidak selalu konsisten. Hal ini menunjukkan adanya indikasi saturasi performa, yaitu penambahan jumlah konteks tidak selalu menghasilkan peningkatan kualitas jawaban yang signifikan.



Gambar 2.1 Grafik Perbandingan Metrik Kualitas Jawaban terhadap Top-K

Gambar 2.1 memperlihatkan perubahan nilai ROUGE-1, ROUGE-2, ROUGE-L, BLEU, dan BERTScore F1 pada variasi Top-K = 1, 3, 5, dan 10. Secara umum, nilai ROUGE meningkat dari K=1 ke K=3, kemudian cenderung stabil atau sedikit menurun pada K=5 dan K=10. Nilai ROUGE-1 tertinggi diperoleh pada K=3 sebesar 0,3416, sedangkan ROUGE-L tertinggi diperoleh pada K=5 sebesar 0,3403. Nilai BLEU meningkat paling tinggi pada K=10 dengan nilai 23,0064. Sementara itu, BERTScore F1 relatif stabil pada seluruh variasi K, dengan rentang 0,6966 hingga 0,7141. Hasil ini menunjukkan bahwa penambahan konteks dapat meningkatkan kualitas jawaban hingga titik tertentu, tetapi peningkatannya tidak selalu konsisten ketika nilai Top-K semakin besar.


2.4 Hasil Evaluasi Sitasi

Selain kualitas jawaban, evaluasi juga dilakukan terhadap kemampuan sistem dalam menemukan dokumen yang relevan dan menghasilkan sitasi yang sesuai dengan sumber informasi yang digunakan.

Top-K	Retrieval Hit Rate	Citation Hit Rate	Invalid Citation Count	No Citation Rate	Citation Hallucination Rate
1	0.56	0.28	4	0.42	0.72
3	0.76	0.36	2	0.32	0.64
5	0.76	0.44	3	0.24	0.56
10	0.88	0.46	0	0.24	0.54


Tabel 2.4 Hasil Evaluasi Retrieval dan Sitasi pada Berbagai Nilai Top-K

Retrieval Hit Rate menunjukkan proporsi pertanyaan yang berhasil menemukan dokumen yang mengandung jawaban benar pada tahap retrieval. Citation Hit Rate menunjukkan proporsi jawaban yang menghasilkan sitasi yang sesuai dengan dokumen sumber. Invalid Citation Count menunjukkan jumlah sitasi yang tidak valid, yaitu sitasi yang merujuk pada nomor dokumen yang tidak tersedia dalam konteks. No Citation Rate menunjukkan proporsi jawaban yang tidak menyertakan sitasi, sedangkan Citation Hallucination Rate menunjukkan tingkat kegagalan sitasi yang dihitung sebagai $1 - \text{Citation Hit Rate}$.



Gambar 2.2 Grafik Retrieval Hit Rate dan Citation Hit Rate terhadap Top-K

Gambar 2.2 menunjukkan perbandingan Retrieval Hit Rate dan Citation Hit Rate pada berbagai nilai Top-K. Retrieval Hit Rate meningkat dari 0,56 pada K=1 menjadi 0,76 pada K=3 dan K=5, kemudian mencapai 0,88 pada K=10. Hal ini menunjukkan bahwa semakin banyak dokumen yang diambil oleh retriever, semakin besar peluang dokumen yang mengandung jawaban benar ikut masuk ke dalam konteks. Citation Hit Rate juga meningkat dari 0,28 pada K=1 menjadi 0,46 pada K=10. Meskipun demikian, nilai Citation Hit Rate masih berada di bawah Retrieval Hit Rate pada seluruh nilai K. Hal ini menunjukkan bahwa keberhasilan retriever dalam menemukan dokumen relevan belum selalu diikuti oleh kemampuan generator untuk memberikan sitasi yang benar.



Gambar 2.3 Grafik Jumlah Invalid Citation terhadap Top-K

Gambar 2.3 menunjukkan jumlah sitasi tidak valid pada setiap nilai Top-K. Invalid Citation Count tertinggi ditemukan pada K=1 sebanyak 4 kasus. Pada K=3 ditemukan 2 kasus, pada K=5 ditemukan 3 kasus, sedangkan pada K=10 tidak ditemukan sitasi tidak valid. Hasil ini menunjukkan bahwa model masih dapat menghasilkan sitasi yang tidak valid pada beberapa variasi nilai K, terutama ketika jumlah konteks masih terbatas. Namun, pada K=10, seluruh sitasi yang muncul merujuk pada nomor dokumen yang tersedia dalam konteks. Meskipun demikian, evaluasi sitasi tetap diperlukan karena sitasi yang valid secara format belum tentu selalu merujuk pada dokumen yang benar-benar mendukung jawaban.

3. ANALISIS DAN DISKUSI

3.1 Analisis Saturasi Performa pada Berbagai Nilai K

Berdasarkan Tabel 2.3, nilai ROUGE-1 mengalami peningkatan dari 0,2901 pada K=1 menjadi 0,3416 pada K=3. Setelah itu, nilai ROUGE-1 relatif stabil pada K=5 dan K=10 dengan nilai masing-masing sebesar 0,3390 dan 0,3349. Pola yang serupa juga terlihat pada ROUGE-2 dan ROUGE-L. Nilai ROUGE-2 meningkat dari 0,1843 pada K=1 menjadi 0,2229 pada K=3, kemudian mengalami sedikit penurunan pada K=5 dan K=10. Sementara itu, ROUGE-L meningkat dari 0,2807 pada K=1 menjadi 0,3401 pada K=3 dan tetap berada pada rentang yang relatif serupa pada nilai K yang lebih besar. Nilai BLEU menunjukkan pola yang berbeda dibandingkan metrik ROUGE. Nilai BLEU meningkat dari 16,9753 pada K=1 menjadi 17,5177 pada K=3, relatif stabil pada K=5 dengan nilai 17,2756, kemudian meningkat menjadi 23,0064 pada K=10. Di sisi lain, nilai BERTScore F1 berada pada rentang 0,6966-0,7141 dan hanya mengalami perubahan yang relatif kecil pada seluruh variasi K. Hasil tersebut menunjukkan bahwa kesamaan semantik antara jawaban yang dihasilkan model dan jawaban referensi cenderung konsisten pada seluruh nilai K yang diuji.

Pada tahap retrieval, Retrieval Hit Rate meningkat dari 0,56 pada K=1 menjadi 0,76 pada K=3 dan K=5, kemudian mencapai 0,88 pada K=10. Peningkatan tersebut menunjukkan bahwa semakin banyak dokumen yang diambil, semakin besar kemungkinan dokumen yang mengandung jawaban benar berhasil ditemukan oleh retriever. Jika dibandingkan antara variasi K, perubahan metrik yang paling terlihat terjadi ketika nilai K dinaikkan dari 1 menjadi 3. Setelah K mencapai 3, sebagian besar metrik kualitas jawaban hanya mengalami perubahan yang relatif kecil meskipun jumlah dokumen konteks terus ditambah. Kondisi tersebut menunjukkan adanya indikasi saturasi performa, yaitu ketika penambahan dokumen retrieval masih memberikan manfaat, tetapi peningkatan kualitas jawaban yang diperoleh menjadi semakin terbatas dibandingkan jumlah dokumen tambahan yang diberikan sebagai konteks.

3.2 Analisis Perilaku LLM terhadap Sitasi Dokumen

Berdasarkan Tabel 2.4, nilai Retrieval Hit Rate mengalami peningkatan dari 0,56 pada K=1 menjadi 0,76 pada K=3 dan K=5, kemudian mencapai 0,88 pada K=10. Pola yang serupa juga terlihat pada Citation Hit Rate yang meningkat dari 0,28 pada K=1 menjadi 0,36 pada K=3, kemudian meningkat menjadi 0,44 pada K=5 dan 0,46 pada K=10. Sementara itu, jumlah invalid citation menunjukkan kecenderungan menurun dari empat kasus pada K=1 menjadi dua kasus pada K=3, tiga kasus pada K=5, dan tidak ditemukan lagi pada K=10. Nilai No Citation Rate juga mengalami penurunan dari 0,42 pada K=1 menjadi 0,24 pada K=5 dan K=10. Selain itu, Citation Hallucination Rate menurun secara bertahap dari 0,72 pada K=1 menjadi 0,54 pada K=10.

Peningkatan Retrieval Hit Rate menunjukkan peluang ditemukannya dokumen yang mengandung jawaban benar semakin besar dengan semakin bertambahnya jumlah dokumen yang diambil pada tahap retrieval. Kenaikan Citation Hit Rate mengindikasikan bahwa dokumen yang berhasil ditemukan semakin sering digunakan sebagai sumber sitasi dalam jawaban yang dihasilkan. Penurunan invalid citation count, No Citation Rate, dan Citation Hallucination Rate menunjukkan bahwa sitasi yang diberikan model cenderung semakin sesuai dengan dokumen yang tersedia sesuai konteks. Perubahan yang paling terlihat terjadi pada rentang K=1 hingga K=5, sedangkan

peningkatan yang diperoleh setelahnya relatif lebih kecil. Hasil tersebut menunjukkan bahwa penambahan jumlah dokumen retrieval dapat meningkatkan kualitas sitasi dan mengurangi kesalahan referensi, meskipun peningkatan yang diperoleh cenderung lebih kecil pada nilai K yang lebih besar.

4. PEMBAGIAN KERJA

Proyek ini dikerjakan secara kolaboratif oleh seluruh anggota tim. Pembagian tugas dilakukan berdasarkan tiga komponen utama dalam sistem Retrieval-Augmented Generation (RAG), yaitu pipeline retrieval, pipeline generation, dan pipeline evaluation. Selain mengerjakan bagian implementasi kode masing-masing, setiap anggota juga berkontribusi dalam penyusunan laporan sesuai dengan bagian yang dikerjakan.

Anggota	Tugas Implementasi	Kontribusi Laporan
Athaya Naura Khalilah	Bertanggung jawab pada bagian dataset, preprocessing, embedding, dan retriever. Bagian ini mencakup proses load dataset IDK-MRC dari Hugging Face, pengecekan struktur data, pembersihan teks, pemilihan embedding model, encoding dokumen, pembangunan vector store menggunakan FAISS, serta pembuatan fungsi retrieval Top-K.	Mendelegasikan dan membagi tugas kepada anggota tim sehingga seluruh anggota berkontribusi dalam proyek tugas, menulis bagian dataset, preprocessing, embedding model, vector store, dan penjelasan cara kerja retriever. Menjelaskan alasan pemilihan FAISS sebagai komponen retrieval dalam sistem RAG.
Syafran Abdillah Erdin	Bertanggung jawab pada bagian generator LLM dan prompt RAG. Bagian ini mencakup proses load LLM, pembuatan prompt RAG, format konteks menjadi nomor referensi seperti [1], [2], [3], pembuatan instruksi agar model menjawab dengan sitasi, parsing sitasi dari output model, serta integrasi antara retriever dan generator. Melakukan eksperimen yang mencakup pelaksanaan eksperimen untuk variasi nilai K = 1, 3, 5, dan 10	Menulis bagian model LLM yang digunakan, alasan pemilihan model, rancangan prompt, mekanisme pemberian sitasi, serta kendala yang muncul pada proses generation seperti jawaban tanpa sitasi, sitasi salah, atau halusinasi sitasi.
Geraldine Angelie Tari Damauly Hutagalung	Bertanggung jawab pada bagian evaluasi dan penyimpanan output jawaban model, perhitungan metrik evaluasi seperti ROUGE, BLEU, dan BERTScore, perhitungan retrieval hit rate, citation hit rate, serta pembuatan tabel dan grafik hasil eksperimen.	Menulis bagian hasil eksperimen, tabel metrik, grafik performa terhadap variasi nilai K, grafik atau tabel akurasi sitasi, serta penjelasan metrik evaluasi yang digunakan dalam penelitian ini.

Selain pembagian tugas utama tersebut, seluruh anggota tim juga berkontribusi dalam proses integrasi notebook, debugging, pengecekan ulang hasil eksperimen, serta penyusunan analisis dan diskusi. Analisis yang dikerjakan bersama meliputi pembahasan performa RAG ketika nilai dari K bertambah, pengaruh jumlah konteks terhadap kualitas jawaban, perilaku LLM dalam menghasilkan sitasi, serta potensi halusinasi sitasi ketika jumlah dokumen konteks semakin banyak.

5. LAMPIRAN

Link GitHub:

<https://github.com/athayanaura/Final-Project-KSSC>

Link Google Colab:

https://colab.research.google.com/drive/1TlgZ_J_Akg4nDYHKuTptoTE2LAtbGNfr?usp=sharing

Catatan:

Beberapa output pada notebook Google Colab dapat terlihat ganda karena sebagian cell dijalankan lebih dari satu kali. Namun, hasil akhir yang digunakan dalam laporan mengacu pada tabel evaluasi akhir dan grafik yang tercantum pada bagian Hasil Eksperimen.